UNIVERSITÀ DEGLI STUDI DI MILANO-BICOCCA

Scuola di Economia e Statistica
Corso di laurea in

STATISTICA E GESTIONE DELLE INFORMAZIONI

Confronto tra modelli ETS e ARIMA nella previsione delle serie storiche finanziarie

Relatore:
Prof. Marco Fattore

Tesi di Laurea di:
Marco Pozzoli
Matr. N. 902914

Anno Accademico 2024/25

Abstract

In questo studio è stata approfondita la costruzione di modelli ARIMA ed ETS per la previsione di serie storiche finanziarie, incluso il delineamento di una *best practice* da seguire per ottenere un buon modello. In particolare, sono stati trattati il tipo di modello, il preprocessing, la dimensione del dataset di training, l'orizzonte e la stagionalità, cercando il nesso tra la scelta migliore e le caratteristiche intrinseche della serie. È stato effettuato anche un approfondimento relativo all'aggiunta di regressori esterni e un confronto con modelli XGBoost, che ha portato alla conferma della bontà di adattamento e generalizzazione dei modelli ARIMA ed ETS senza variabili esogene.

1 Introduzione

La previsione delle serie storiche finanziarie rappresenta una sfida complessa e rilevante nell'ambito statistico e finanziario. Consiste nell'analisi di dati storici ordinati temporalmente con l'obiettivo di stimare i valori futuri. In genere si tratta di prezzi azionari, tassi di cambio, indici di mercato o materie prime. L'obiettivo è l'ausilio alla formulazione di strategie decisionali e l'ottimizzazione di portafogli di investimento. La complessità della previsione scaturisce dalla natura delle serie finanziarie: si tratta infatti di serie non stazionarie, rumorose, talvolta caratterizzate da grandi picchi e valori anomali. Le variazioni di livello sono inoltre dovute a molteplici cause, la cui totalità è generalmente impossibile da individuare e quantificare.

Per questo il presente lavoro si pone l'obiettivo di studiare, mediante i modelli ARIMA ed ETS, la previsione del livello delle serie finanziarie, comparando i risultati dei due modelli e delineando una *bestpractice* robusta, ossia un procedimento facilmente replicabile per costruire un buon modello. Per questo motivo l'approccio utilizzato è massivo, ossia prende in considerazione decine di migliaia di modelli costruiti con parametri diversi su serie diverse, in modo da permettere l'estrapolazione delle condizioni per cui i modelli migliorano le proprie performance.

Lo studio si concentra sull'ottimizzazione di metriche quali MAPE e RMSE, e sul capire quali condizioni la permettono. I parametri vagliati comprendono: caratteristiche delle serie, tipologia del modello, pre-processing dei dati, dimensione del dataset di training, orizzonte di previsione e stagionalità.

Vengono infine introdotti dei regressori esterni in uno studio mirato su singole serie, con l'obiettivo di spiegare la variazione della serie oggetto di studio laddove il modello non è in grado, in modo da migliorare ulteriormente la previsione e studiarne gli effetti.

2 Metodi

In questa sezione, la teoria e i metodi alla base dello studio sono esposti.

2.1 Serie storiche finanziarie

Una serie storica è una sequenza di osservazioni misurate in momenti ordinati temporalmente. In questo studio la variabile di interesse è il livello delle serie finanziarie, che può essere un prezzo di azioni o materie prime, indici di borsa o tassi di cambio.

Le serie finanziarie sono generalmente non stazionarie, né in senso forte né in senso debole. Questo significa che, data Y_t variabile casuale al tempo t, la probabilità congiunta varia nel tempo,

$$P(Y_{t_1} = y_1, \ldots, Y_{t_k} = y_k) \neq \mathbf{P}(Y_{t_1+h} = y_1, \ldots, Y_{t_k+h} = y_k)$$

non rimane costante in media e la covarianza tra variabili non dipende soltanto dalla distanza temporale.

$$\exists t, k : E(Y_t) \neq E(Y_k)$$
$$\exists t, k : Cov(Y_t, Y_k) \neq Cov(Y_{t+h}, Y_{k+h}), h \neq 0$$

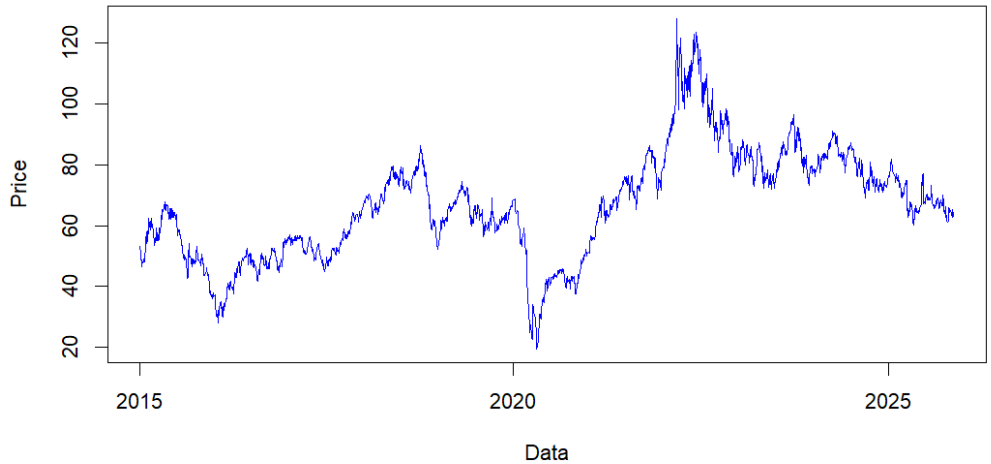

Esempio di serie storica finanziaria (Brent crude oil price)

2.1.1 Valutazione

Considerato l'obiettivo dello studio, è necessario conoscere le caratteristiche delle singole serie, cercando di descriverle mediante alcune variabili che potranno essere usate per capire quali aspetti dei dati portano a prediligere una specifica tipologia di modello, pre-processing, etc.
Le variabili utilizzate sono le seguenti:

- **Trend**: è una misura che indica come varia la media della serie nel lungo periodo. Il valore, compreso tra 0 e 1, indica quanto la serie è dominata dal trend. Viene calcolato secondo la seguente formula:

  $$trend = 1 - \frac{Var(e_t)}{Var(f_t + e_t)})$$

  dove e_t è la componente residua e f_t è la componente trend. Le componenti e_t , f_t e s_t (ossia la componente stagionale), sono calcolate mediante la STL *decomposition* (*Cleveland et al. 1990*).

- **Seasonal strength**: è la misura che indica l'importanza della componente stagionale rispetto alla serie, si calcola in maniera analoga al trend:

  $$seasonal.strength = 1 - \frac{Var(e_t)}{Var(s_{i,t} + e_t)}$$

  I valori di Trend e Seasonal strength non compresi nell'intervallo $[0; 1]$ vengono posti come uguali all'estremo più vicino.

- **Linearity**: è una misura della linearità della serie. Viene calcolata basandosi sui coefficienti della regressione ortogonale quadratica sulla serie.

- **Spike**: è una misura della spigolosità della serie, ed è calcolata come la varianza delle varianze $leave - one - out$ della componente e_t.

- **Numero di outliers**: è il numero di valori anomali presenti nella serie. Sono fonte di diverse problematiche: si presuppone che il modello non sia in grado di spiegarli. Gli outliers sono individuati partendo dalla componente e_t della serie, e ipotizzando una distribuzione approssimativamente normale della stessa. Vengono etichettati come valori anomali

le entrate che hanno valori al di fuori della soglia basata sui quartili (Tukey, 1977):

$$R_t < Q_1 - 3 \cdot IQR \longleftrightarrow R_t > Q_3 + 3 \cdot IQR$$

- **Volatilità**: è la misura della variazione del prezzo di uno strumento finanziario nel tempo. È calcolata come:

$$\text{Volatilità} = Var(Y) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \mu_Y)^2$$

- **Volatilità ultimi 30 giorni**: è calcolata allo stesso modo della volatilità normale, facendo però riferimento al periodo delle ultime trenta osservazioni.

- **ACF1**: è la funzione di autocorrelazione, misura della correlazione di una variabile casuale con sé stessa a un tempo precedente:

$$ACF1 = \gamma_1 = cov(Y_t, Y_{t-1})$$

Le metriche trend, seasonal strength, linearity, spike e ACF1 sono calcolate con l'ausilio della libreria $tsfeatures$ 1.1.1 (*Hyndman et al.*).

2.2 Modelli di previsione

In questa sezione viene approfondito l'aspetto teorico che riguarda i due modelli oggetto di studio, ossia i modelli ARIMA (*modello autoregressivo a media mobile*) ed ETS (*Exponential Smoothing Models*). Sono esposte anche le variazioni che includono l'integrazione di regressori esterni, punto focale della parte finale dello studio.

Questi modelli hanno la capacità fondamentale di trattare serie storiche caratterizzate da non stazionarietà, permettendo dunque l'analisi delle serie finanziarie. I modelli della famiglia ARIMA si basano sull'autocorrelazione, mentre i modelli ETS sono basati sullo smoothing esponenziale.

2.2.1 Modelli ARIMA

I modelli ARIMA (AutoRegressive Integrated Moving Average) nascono come sviluppo dei modelli ARMA, data la loro impossibilità di modellare serie non stazionarie.
Sono definiti come:

$$\Phi_p(B)(I-B)^d Y_t = \Psi_q(B)\epsilon_t$$

I modelli $ARIMA(p,d,q)$ compiono l'integrazione della serie, ossia una differenziazione dei valori fino a quando la serie non diventa stazionaria. Il numero di differenziazioni è indicato dal parametro d. Se $d = 0$ il modello corrisponde a un $ARMA(p,q)$. La differenziazione consiste in:

$$\Delta Y_t = Y_t - Y_{t-1} = (I-B)Y_t$$

dove I è l'identità e B l'operatore *backwards*, che restituisce il valore di Y al tempo precedente.

Il parametro p riguarda la parte autoregressiva del modello, che definisce la dipendenza lineare tra l'osservazione corrente e le p osservazione passate della serie. Dunque ha formula:

$$\sum_{i=1}^{p} \phi_i Y_{t-i}$$

Il parametro q invece concerne la parte a media mobile, che modella l'errore corrente ϵ_t come combinazione lineare dei q errori passati:

$$\sum_{j=1}^{q} \psi_j \epsilon_{t-j}$$

Perciò in una serie differenziata:

$$Y'_t = \sum_{i=1}^{p} \phi_i Y'_{t-i} + \sum_{j=1}^{q} \psi_j \epsilon_{t-j} + \epsilon_t$$

L'identificazione dei parametri avviene prima differenziando la serie d volte, fino a quando è graficamente stazionaria. L'identificazione dei parametri p e q avviene invece osservando i valori di ACF e PACF della serie differenziata, ossia il numero di distanze temporali per cui il valore si avvicina a zero.

La stima dei coefficienti del modello ϕ_i e ψ_j avviene, una volta differenziata la serie, usando la stima di massima verosimiglianza.

La struttura ARIMA può essere estesa nel modello $SARIMA(p,d,q)(P,D,Q)_m$ che introduce una componente legata alla stagionalità periodica (ad esempio giornaliera o settimanale). Lo scriviamo come:

$$\Phi(B)\Phi_s(B^s)(I-B)^d(I-B)^D Y_t = \Psi(B)\Psi_s(B^s)\epsilon_t$$

I parametri P, D, Q sono analoghi a quelli di ARIMA, facendo però riferimento ai periodi stagionali.

2.2.2 ARIMA con regressori esterni

Nei modelli ARIMA tutta l'informazione è estrapolata dalla serie stessa e dal suo andamento. È possibile integrare nella spiegazione della serie informazioni derivanti da variabili esogene. Questo avviene tramite una regressione con errori ARMA.

L'idea è quella di compiere una regressione delle variabili esogene sulla serie, non in forma ordinata, per poi modellare i residui con un modello ARMA, cogliendo ciò che i regressori non sono stati in grado di spiegare. Lo possiamo scrivere come:

$$y_t = \beta^T \underline{x}_t + \Phi(B)^{-1}\Psi(B)\epsilon_t$$

dove β è il vettore dei ceofficienti di regressione e $\underline{x}$ è il vettore di regressori.

2.2.3 Modelli ETS

I modelli ETS (*Exponential Smoothing Models*) si approcciano diversamente rispetto agli ARIMA nel trattare la non stazionarietà. Se in ARIMA è una caratteristica da eliminare, ETS si pone l'obiettivo di modellarla.

Questi modelli modellano la serie come un'insieme di errore, trend e stagionalità, cercando di individuare la struttura sottostante alla serie, compiendo una vera e propria scomposizione delle componenti. In particolare:

$$y_t = l_{t-1} + b_{t-1} + s_{t-m} + \epsilon_t \text{ , dove}$$

$$\begin{aligned} l_t &= l_{t-1} + b_{t-1} + \alpha\epsilon_t \\ b_t &= b_{t-1} + \beta\epsilon_t \\ s_t &= s_{t-m} + \gamma\epsilon_t \end{aligned}$$

La componente stagionale è stimata sotto un vincolo di normalizzazione, per cui tutti i parametri stagionali devono avere somma nulla: $s_0 + ... + s_{-m+1} = 0$.

Il modello ETS enunciato viene denominato ETS(A,A,A), in quanto ha errore, trend e stagionalità additivi. È tuttavia modificabile. Le tre componenti possono essere stimate in forma moltiplicativa invece che additiva, cambiando il rispettivo parametro in "M". Trend e stagionalità possono essere rimossi, segnalandolo col parametro "N". Al trend può essere introdotto un "*damping factor*" $\phi \in (0; 1]$, che "smorza" il trend e tende a garantire previsioni più realistiche, e viene indicato col parametro "A_d".
La stima dei parametri avviene per massima verosimiglianza condizionata.

2.2.4 ETS con regressori esterni

Un limite rilevante dell'ambiente `R` è l'assenza di una funzione che implementi modelli ETS con regressori esterni. Nonostante tali modelli siano ben definiti a livello teorico, il pacchetto *forecast* non include un'estensione dei modelli ETS che permetta l'inclusione diretta di variabili esogene (Hyndman, Athanasopoulos, *Forecasting: Principles and Practice, 2022*).

Per sopperire a questa mancanza, la pratica applicata ricorre comunemente ai modelli *tslm* (*Time Series Linear Models*), che rappresentano la soluzione metodologicamente corretta per ottenere una struttura molto simile agli ETS estesi con regressori. La documentazione ufficiale del pacchetto *forecast* afferma infatti che: *"tslm() is used to fit linear models to time series including trend and seasonality components."*

Il modello TSLM permette di rappresentare la serie come una combinazione di tre elementi:

- un termine di **trend**, spesso modellato come funzione lineare del tempo;
- una componente **stagionale**, modellata tramite variabili *dummy* o funzioni periodiche;
- uno o più **regressori esterni**, incorporati nella formulazione lineare.

La forma generale del modello può essere espressa come:

$$y_t = \beta_0 + \beta_1 t + \beta_2 S_t + \beta^T \underline{x}_t + \epsilon_t$$

dove t rappresenta il trend, S_t la componente stagionale (spesso espressa sotto forma di variabili dummy), $\underline{x}_t$ il vettore dei regressori esterni e ϵ_t un *white noise*.

Dal punto di vista concettuale, il TSLM replica la struttura deterministica di un ETS additivo: il trend e la stagionalità vengono modellati esplicitamente, mentre l'incertezza residua è delegata al termine d'errore. Per questo motivo, è considerato nella letteratura un sostituto naturale degli ETS con covariate quando si opera in ambiente *R*. Hyndman e Athanasopoulos (2022) includono infatti i modelli TSLM tra gli strumenti principali per incorporare regressori esterni in modo coerente e trasparente nella previsione. È confermato da Hyndman in una nota tecnica che il modello *tslm* è stato introdotto proprio per fornire una struttura unificata per regressione, trend e stagionalità, in assenza di un modulo ETS con regressori (*Hyndman, Hyndsight Blog, 2016*).

2.3 Pre-Processing

Il pre-processing, ossia il trattamento dei dati precedente alla modellizzazione, è un passaggio cruciale nella costruzione dei modelli, che permette di rispettare le ipotesi fondamentali dei modelli lineari, in particolare l'omoschedasticità e la normalità dei residui, essenziali per ottenere un modello robusto.

Nelle serie finanziare è molto comune l'eteroschedasticità, dato che la volatilità della serie tende a cambiare in periodi diversi. Molto comuni sono anche gli outliers e spikes, ossia valori anomali che possono distorcere la stima dei parametri del modello.

In questo studio sono stati utilizzati quattro diversi metodi di pre-processing, in modo da poter confrontare i risultati e individuare quando, date le caratteristiche di una serie, conviene usarli. In particolare sono stati confrontati i dati grezzi ("*Raw*"), le trasformazioni Box-Cox, log-returns e infine la rimozione dei valori anomali.

2.3.1 Trasformazione Box-Cox

La trasformazione Box-Cox (Box,Cox, *"An Analysis of Transformations", 1964*) è una delle trasformazioni più popolari per quanto riguarda la stabilizzazione della varianza. Come accennato, le serie finanziare sono caratterizzate da grande eteroschedasticità, dovuta a periodi connotati da diverse volatilità e andamenti più o meno turbolenti del mercato. Questa trasformazione è incentrata sul miglioramento della linearità dei dati, che, di conseguenza, stabilizza la varianza e la normalità dei residui.
Questa trasformazione avviene secondo la seguente formula:

$$Y_t \longrightarrow Y_t'(\lambda) = \begin{cases} \dfrac{Y_t^{\lambda} - 1}{\lambda}, & \lambda \neq 0 \\ ln(Y_t), & \lambda = 0 \end{cases}$$

dove λ viene selezionata secondo un processo di massima verosimiglianza, mirato a ridurre la metrica $RMSE$ (sez. 2.4.1). Perciò il modello costruito sui dati trasformati avrà sempre un $RMSE$ minore (per quanto riguarda i dati di *training*) di quello costruito sui dati "*raw*, il che non comporta necessariamente performance migliori nelle previsioni su dati nuovi.

2.3.2 Trasformazione Log-returns

Un'altra trasformazione ampiamente adottata nell'analisi delle serie finanziarie è quella in log-returns. A differenza delle trasformazioni dirette sui livelli della serie, i log-returns modellano le variazioni percentuali tra due istanti consecutivi:

$$Y_t' = \ln\left(\frac{Y_t}{Y_{t-1}}\right) = \ln(Y_t) - \ln(Y_{t-1})$$

Questa trasformazione presenta diversi vantaggi. In primo luogo, riduce drasticamente l'eteroschedasticità tipica dei livelli della serie, producendo una sequenza più stabile nel tempo. In secondo luogo, i rendimenti logaritmici risultano più vicini a una distribuzione simmetrica, caratteristica che facilita la modellizzazione con modelli lineari e ne migliora l'interpretabilità. Infine, i log-returns sono additivi nel tempo, proprietà molto utile in applicazioni finanziarie.

È importante sottolineare che, mentre la trasformazione Box–Cox agisce sui livelli della serie, i log-returns rimuovono completamente l'informazione

sul livello del processo, concentrandosi esclusivamente sulle sue variazioni. Per questo motivo a livello pratico è stata necessaria una ricostruzione del livello in fase di previsione e valutazione delle metriche.

2.3.3 Rimozione outliers

La presenza di outliers rappresenta un ulteriore elemento critico nelle serie finanziarie. Valori estremi, spesso associati a eventi di mercato eccezionali, possono influenzare negativamente la stima dei coefficienti e compromettere la capacità del modello di adattarsi ai pattern strutturali della serie, aumentando la varianza nella stima dei coefficienti.

La rimozione degli outliers non mira a eliminare gli *shock* di mercato, che sono parte integrante della serie, quanto a migliorare la stima dei coefficienti, che impedirebbe una generalizzazione del modello.

L'individuazione degli outliers avviene come descritto nel paragrafo 2.1.1, nella sezione dedicata al numero di outliers.

I valori anomali vengono poi sostituiti tramite un'interpolazione lineare costruita usando i valori vicini, ripetendo questo processo fino a quando non si rilevano più outliers (R. Hyndman, *Detecting time series outliers*).

2.4 Configurazione parte prima - Studio dei modelli senza regressori esterni

In questa sezione viene esposta la metodologia di studio relativa ai modelli senza l'aggiunta di regressori esterni. In particolare come sono stati ricavati i dati da cui sono state estratte i risultati e le conclusioni. L'obiettivo di questa prima parte è quello di capire come costruire un buon modello per la previsione delle serie. I parametri di cui si è valutata l'influenza sono esposti nella sezione di seguito.

L'approccio è stato quello di costruire decine di migliaia di modelli su serie diverse e con parametri diversi per poi misurarne le performance di previsione su dati nuovi, in modo da poterli confrontare e poter estrapolare informazioni relative alla costruzione ideale del modello in ogni situazione.

2.4.1 Costruzione dei modelli

Alla base della prima parte dello studio c'è la costruzione dei dati da intepretare. Come accennato, l'idea è quella di costruire decine di migliaia di modelli, variando i parametri, e misurarne le performance.

La scelta delle serie non è stata casuale, volendo condurre uno studio robusto. Le serie sono quanto più diversificate. Sono presenti indici azionari, ETF settoriali, tassi di cambio, materie prime, obbligazioni, criptovalute e altri, in modo da avere serie con caratteristiche diverse. In totale sono state utilizzate 167 serie finanziarie. Tutte le serie sono state scaricate da Yahoo finance, tramite il pacchetto "*quantmod*", che permette di ottenere le serie ordinate per data. In particolare per i valori delle serie è stato deciso di usare i valori alla chiusura della borsa. Le serie sono scaricate con valori a partire dal 01/01/2015.

Raccolte le serie, è stata condotta una grid-search parallela, progettata per costruire, per ogni serie, modelli ETS e ARIMA, variando i seguenti parametri:

- **Inizio del periodo di training**, ossia la dimensione del dataset su cui i modelli sono allenati. Le soglie utilizzate sono quattro e prendono come inizio il primo valore degli anni 2015, 2020, 2023 e 2025. La prima garantisce un periodo molto lungo di circa 10 anni, con circa 2600 osservazioni. La seconda contiene la metà delle osservazioni, e l'inizio durante il periodo influenzato dalla pandemia dovuta al Covid-19, caratterizzato da grande volatilità, potrebbe influenzare le stime dei coefficienti. Il 2023 inizia in un periodo antecedente alla pandemia, dunque meno volatile, anche se con meno osservazioni. Infine il 2025 riporta solamente le osservazioni dell'ultimo anno, è dunque interessante valutare le performance dei modelli allenati su poche osservazioni recentissime.

- **Orizzonte di previsione**: i modelli vengono valutati su diverse orizzonti, cioè su quanto è accurata la previsione a distanza di un certo numero di periodi. In particolare è stata valutata a distanza di 15, 30, 45, 60 e 120 giorni. Questo garantisce uno spettro ampio di valutazioni, a breve, medio e medio-lungo termine. Orizzonti maggiori non

sono stati presi in considerazione in quanto eventi esterni e le caratteristiche dei modelli non garantiscono robustezza delle previsioni.

- **Stagionalità**: altro parametro considerato è la stagionalità delle serie. Per ognuna sono stati valutati modelli senza stagionalità, stagionalità settimanale e mensile, attraverso il parametro $frequency$ della funzione $ts()$, che costruisce le *time-series* da modellare.

- **Pre-Processing**: Per ogni modello vengono testati i diversi tipi di trattamento dei dati visti nella sezione 2.3.

Una volta costruiti i modelli, vengono valutate le performance su dati *in-sample* (train) e *out-of-sample* (test). Vengono calcolate diverse metriche di accuratezza:

- MAE (*Mean Absolute Error*): è la media del modulo degli errori, è dipendente dalla scala della serie, pertanto non può essere usato per confronti tra modelli su serie diverse.

$$MAE = \frac{1}{t-1} \sum_{i=2}^{t} |e_i|$$

- RMSE (*Root Mean Square Error*): è la radice quadrata della media degli errori al quadrato. Essendo dipendente dalla scala della serie, è utilizzabile solo per confronti tra modelli calcolati sulla stessa serie.

$$RMSE = \sqrt{\frac{1}{t-1} \sum_{i=2}^{t} e_i^2}$$

- MAPE (*Mean Absolute Percentage Error*): è la media del valore assoluto dell'errore in percentuale. È indipendente dalla scala della serie, dunque è utile per confrontare modelli di serie diverse, tuttavia soffre quando i valori della serie si avvicinano allo zero, in quanto restituisce valori molto grandi.

$$MAPE = \frac{1}{t-1} \sum_{i=2}^{t} 100 |\frac{e_i}{y_i}|$$

- MASE (*Mean Absolute Scaled Error*): è un confronto del modello con un modello triviale per cui $\hat{y}_t = y_{t-1}$. Un $MASE < 1$ indica una performance migliore.

$$MASE = \frac{\frac{1}{t-1}\sum_{i=2}^{t}|e_i|}{\frac{1}{t-1}\sum_{i=2}^{t}|y_i - y_{i-1}|}$$

- ACF: viene misurata anche l'autocorrelazione dei residui, che indica l'informazione residua non catturata dal modello.

Vengono infine calcolati AIC (*Akaike Information Criterion*) e BIC (*Schwarz Bayesian Information Criterion*), ossia misure del compromesso parsimonia-adattamento dei modelli, in cui valori minori corrispondono a modelli migliori. È generalmente importante avere un buon compromesso, giustificando la complessità del modello con l'aggiunta di regressori, tuttavia nello studio ha un'importanza relativa, trattandosi di modelli non troppo complessi per permettere una costruzione quasi immediata.
Vengono utilizzati dal pacchetto $forecast$ nella selezione del modello al momento della costruzione. Dati un set di parametri per la modellizzazione, vengono vagliati diversi modelli con diversi parametri interni (es. p, d, q in ARIMA, sez. 2.2.1) e viene preso come miglior modello quello con AIC migliore. Data $L(\underline{\theta})$, funzione di verosimiglianza di un modello, calcoliamo le metriche come:

$$AIC = -2 \cdot lnL(\underline{\theta}) + k \cdot \frac{2n}{n-k-1}$$
$$BIC = -2 \cdot lnL(\underline{\theta}) + k \cdot ln(n)$$

dove k è il numero di parametri e n è il numero di osservazioni nel dataset di training.

2.4.2 Interpretazione

Una volta ricavati i dati relativi ai modelli, si può procedere con l'interpretazione, estrapolando le informazioni vere e proprie.

Per fare questo si ricorre a modelli e test statistici con finalità interpretativa. Un passaggio chiave prima di ricorrere a questi mezzi è quello di estrapolare le caratteristiche delle serie (come spiegato nella sez.2.1.1) e congiungere il dataset contenente le performance di test a quello contenente le informazioni delle serie, in modo da avere in ogni riga, cioè per ogni modello, le informazioni riguardo le performance, i parametri di costruzione e la serie. Possiamo ora procedere all'interpretazione.

Tipologia modello e pre-processing Per analizzare le condizioni in cui è meglio usare una specifica tipologia di modello e quale pre-processing l'idea è quella di individuare il miglior modello per ogni serie dopo aver filtrato per orizzonte, in modo da ottenere un dataframe per ogni orizzonte che contiene le informazioni riguardanti il miglior modello e la serie. Il dataset va filtrato per orizzonte in quanto ovviamente con l'orizzonte tende ad aumentare anche l'errore (sez. 3.5), e dunque il confronto non sarebbe sensato, oltre che privo di interesse.

Per fare il confronto si ricorre all'utilizzo degli alberi decisionali CART (*Classification and Regression Trees*) per la classificazione. La scelta è dovuta all'alta interpretabilità che garantiscono.

Questi modelli sono basati sulla definizione di regole di suddivisione binarie. Partendo dall'insieme dei dati, l'algoritmo valuta tutte le variabili esplicative e tutte le soglie per creare uno *split*, con l'obiettivo di ottenere una suddivisione che garantisce due insiemi il più omogenei possibile, valutato attraverso l'indice di Gini. Questo procedimento viene ripetuto fino al raggiungimento del criterio di arresto, generalmente legati alla dimensione dell'albero. Essendo non parametrico non richiede la verifica di assunzioni preliminari, e coglie relazioni non lineari. Il costo dell'alta interpretabilità è la tendenza all'$overfitting$.

Nello studio il modello viene impostato con il miglior modello come target e le caratteristiche della serie come covariate, in modo da ottenere una spiegazione della scelta tra ETS e ARIMA. Lo stesso avviene per il pre-processing.

Stimato il modello, è possibile usare la funzione $vi()$ (*Vip package 0.4.1*) per ottenere l'ordine di importanza delle variabile nella discriminazione.

Test statistici per la significatività delle differenze Per confrontare gli effetti della data di inizio del training e della stagionalità esistono diversi metodi e test statistici. Intuitivamente basterebbe un'analisi della varianza (ANOVA), tuttavia osservando i dati è facile notare la non sussistenza delle assunzioni riguardo i dati. Non sono infatti distribuiti normalmente e non sono omoschedastici. Per questo dobbiamo ricorrere al test di Kruskal-Wallis,

che essendo non parametrico non richiede i presupposti di linearità (Kruskal, Wallis, *Use of Ranks in One-Criterion Variance Analysis*). La statistica test è data da:

$$H = (N-1)\frac{\sum_{i=1}^{g} n_i(\overline{r_{i\cdot}} - \overline{r})^2}{\sum_{i=1}^{g}\sum_{j=1}^{n_i}(r_{ij} - \overline{r})^2}$$

dove:

- N è il numero totale di osservazioni
- g è il numero di gruppi
- n_i è il numero di osservazioni nel gruppo i
- r_{ij} è l'ordine dell'osservazione (rango) j nel gruppo i
- $\overline{r}_{i\cdot}$ è il rango medio del gruppo i
- $\overline{r}$ è il rango medio totale

Questo test tende ad avere molti errori di tipo I, perciò viene applicata la correzione di Bonferroni. La decisione di rifiutare l'ipotesi H_0 di insignificanza delle differenze viene presa confrontando la statistica H con un valore H_c calcolato dal software.

Successivamente è possibile usare il test di Dunn (Dunn, *Multiple comparisons using rank sums*) per identificare le significatività delle differenze tra le coppie. Si basa sul confronto dei ranghi medi $\overline{W}$ e sulla deviazione standard teorica di $y_i = \overline{W_A} - \overline{W_B}$, ottenendo la statistica z_i di Dunn:

$$z_i = \frac{y_i}{\sigma_i}$$

z_i segue una distribuzione approssimativamente normale, permettendoci di calcolare il p-value secondo il classico $p_{val} = P(|Z| \geq |z_i|)$. Anche qui occorre una correzione visto il confronto multiplo, usando Bonferroni.

2.5 Configurazione parte seconda - integrazione di regressori esterni

L'obiettivo della seconda parte dello è quello di studiare l'implementazione di regressori esterni nei modelli, con l'obiettivo di incorporare relazioni tra variabili e migliorare la capacità esplicativa del modello.

La scelta dei regressori rappresenta un passaggio chiave dello studio, ed è stato fatto tenendo a mente relazioni tra le covariate e la serie e l'assenza di multicollinearità tra le serie.

2.5.1 Costruzione dei modelli

L'approccio è molto simile a quello vista nella prima parte, ossia costruendo modelli variando parametri, e misurandone l'efficacia. A causa della necessità di selezione manuale dei regressori, l'approccio è più mirato. Sono state scelte 4 serie diverse tra loro (azioni Apple, indice SP500, prezzo petrolio Brent e la criptovaluta Ethereum), e per ognuna sono stati selezionati 10 regressori secondo i criteri precedentemente enunciati, questi includono inidici di volatilità del mercato, serie analoghe, materie prime e altre tipologie di serie, oltre a variabili dummy.

I modelli vengono creati variando orizzonte, modello e numero di regressori. Ogni modello infatti viene creato senza regressori, poi ne vengono aggiunti 1,2,3,5 e infine 10 variabili. Ogni modello viene allenato e testato su 25 diversi punti della serie, in modo da avere un numero di modelli più elevato e conclusioni più robuste. Una volta creati i modelli, vengono misurate le performance di train e test, in modo da poter fare confronti e trarre conclusioni.

I regressori sono introdotti con valori *laggati*, per motivi di realismo: un modello che si pone l'obiettivo di prevedere valori a s giorni di distanza, avrà come covariate valori con un lag di s giorni, in quanto chiaramente in un'applicazione reale non si ha accesso ai valori futuri delle covariate.

2.5.2 Interpretazione

Le differenze vengono valutate in maniera simile ai punti precedenti. Osservata la non normalità dei dati si ricorre ai test di Kruskal-Wallis e di Dunn per valutare la significatività. In particolare si guardano le differenze tra modelli con numeri di regressori diversi sui dataset suddivisi per orizzonte. Queste differenze sono studiate sia a livello globale che solo su modelli ARIMA o ETS, per avere dei risultati approfonditi.

Per fare un confronto più generale sull'abilità dei modelli di catturare l'informazione delle serie, sono stati costruiti modelli XGBoost di regressione, usando la libreria *xgboost* 1.7.11.1. Il modello XGBoost, o *Extreme Gradient Boosting*, è basato sugli alberi decisionali, e segue l'idea della combinazione di molti modelli più deboli (in genere alberi poco profondi) per costruire un modello robusto. Decretata una $loss\ function$, viene minimizzata mantenendo una penalizzazione per la complessità, evitando $overfitting$. È un modello generalmente molto performante e non richiede particolare preprocessing dei dati. Questo procedimento permette di valutare, partendo dal presupposto della robustezza di XGBoost, la capacità di ETS e ARIMA con e senza regressori esterni di catturaree generalizzare le informazioni della serie e delle variabili esogene.

3 Risultati

In questa sezione vengono mostrati i risultati ottenuti dall'analisi sperimentale, in linea con gli obiettivi stabiliti nelle sezioni precedenti.

3.1 Parte 1 - ARIMA ed ETS

La creazione del modello CART ci permette di estrarre alcune informazioni riguardo il miglior modello per le diverse serie. I dati usati per l'addestramento dei CART è suddiviso per orizzonte, così d poter osservare come cambiano le relazioni all'allungamento della previsione.

- **Orizzonte 15.** ARIMA domina nettamente (70%) ed è preferito quando la volatilità è medio–alta e l'ACF è elevata, indicando maggiore persistenza nel breve periodo. ETS emerge invece in condizioni di volatilità estremamente bassa o quando è presente un numero elevato di outliers. Variabile chiave: *Vol30*.

- **Orizzonte 30.** Si osserva un maggiore equilibrio (ARIMA 57%, ETS 43%). Il driver principale è la *seasonality*: stagionalità bassa favorisce ARIMA, mentre stagionalità alta favorisce ETS. All'interno delle serie stagionali, i *spikes* modulano ulteriormente la scelta: valori elevati riportano la preferenza su ARIMA. ETS rimane vincente quando la serie è stagionale ma poco irregolare.

- **Orizzonte 45.** ARIMA rimane leggermente dominante (58%), ma il ruolo della *volatility* diventa decisivo: volatilità molto bassa porta sempre a ETS. Per volatilità normali, la stagionalità discrimina: stagionalità bassa porta ad ARIMA, stagionalità alta apre biforcazioni regolate da *ACF*. ARIMA prevale con ACF non negativa, ETS con ACF negativa o forte irregolarità.

- **Orizzonte 60.** ARIMA è scelto nel 63% dei casi. La variabile cruciale diventa la *linearity*: serie lineari e poco stagionali sono fortemente associate a modelli ARIMA. ETS emerge invece in presenza di maggiore irregolarità (outliers, spikes o stagionalità elevata).

- **Orizzonte 120.** La distinzione diventa più incerta e l'equilibrio tra i modelli è quasi paritario. La prima partizione è la *seasonality*: stagionalità bassa porta ad ARIMA; stagionalità alta richiede ulteriori

discriminazioni tramite *linearity*, *spikes* e *volatility*. ETS domina dove la struttura è complessa, altamente stagionale o ricca di anomalie.

Nel loro insieme, i risultati mostrano una chiara evoluzione delle preferenze modellistiche al crescere dell'orizzonte previsivo. A breve termine (15–30 giorni) ARIMA risulta generalmente più performante, specialmente per serie caratterizzate da alta volatilità o elevata autocorrelazione. Con il crescere dell'orizzonte (45–60 giorni) la scelta dipende sempre più dalla struttura interna della serie: linearità, stagionalità e presenza di irregolarità diventano determinanti. All'orizzonte più lungo (120 giorni), l'equilibrio tra ARIMA ed ETS suggerisce che nessun modello domina in senso assoluto, e che la scelta dipende in modo critico dalla combinazione tra stagionalità, linearità e intensità degli spikes.

3.2 Parte 1 - Pre-Processing

La stessa cosa è stata fatta per il pre-processing, i risultati sono i seguenti:

- **Orizzonte 15.** La volatilità è la variabile dominante. BoxCox è preferito per volatilità medio–alta, LogRet per volatilità medio–bassa. In presenza di volatilità estremamente elevata vince Outlier, mentre per volatilità molto bassa si mantiene Raw.

- **Orizzonte 30.** Prevalgono LogRet (36%) e BoxCox (32%). Lo split principale è determinato dagli *spikes*: valori molto bassi portano a LogRet, mentre valori più alti richiedono il ruolo del *trend*. BoxCox è favorito quando la volatilità è moderata, LogRet quando è elevata, Raw solo in serie molto lineari.

- **Orizzonte 45.** Prevalgono BoxCox (35%) e LogRet (33%). Variabile cardine: *volatility*. Con volatilità bassa si sceglie LogRet; con volatilità moderata BoxCox; con volatilità molto alta torna LogRet. Raw compare solo in casi estremi con alta volatilità e struttura molto anomala.

- **Orizzonte 60.** La presenza di *spikes* determina il primo nodo: in loro presenza prevale BoxCox. In loro assenza, la sola volatilità discrimina tra LogRet (volatilità bassa o alta) e Raw (volatilità minima). Variables secondarie: ACF e Volatility.

- **Orizzonte 120.** La variabile dominante è il *trend*. Serie con trend marcato scelgono quasi sempre BoxCox; serie senza trend scelgono LogRet. Le successive suddivisioni (Vol30, seasonality, ACF) determinano casi isolati in cui emergono Raw o Outlier.

Il pre-processing mostra invece un quadro molto stabile: la volatilità è la variabile chiave in quasi tutti gli orizzonti. BoxCox è generalmente ottimale per volatilità moderate o in presenza di spikes, mentre LogRet viene preferito per volatilità estremamente basse o molto elevate. La trasformazione Raw o l'eliminazione degli outliers emergono solo in casi particolarmente regolari o altamente irregolari.

3.3 Parte 1 - Inizio training

Il confronto tra performance in base alla data di inizio del dataset di training sarebbe, intuitivamente, da fare usando ANOVA, tuttavia i dati non seguono le assunzioni richieste, come si può notare nel grafico dei residui di ANOVA:

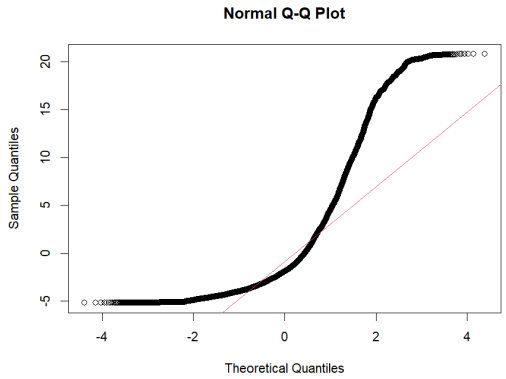

anche trasformando i dati la situazione non cambia: i dati non sono normali. Per questo motivo si deve ricorrere a test non parametrici, che non richiedono le assunzioni di ANOVA. Per questo si usa il Kruskal-Wallis test, che restituisce un $p_{val} = 0.0047$, essendo $P_{val} < 0.05$ si può affermare che ci siano differenze significative tra i $MAPE$ differenziati per $InizioTrain$. Bisogna però vedere le differenze a coppie, per poter interpretare queste differenze.

	Comparison	Z	P.unadj	P.adj
1	2015 - 2020	0.6317554	0.527546711	1.000000000
2	2015 - 2023	0.1440313	0.885475733	0.885475733
3	2020 - 2023	-0.4874482	0.625940776	1.000000000
4	2015 - 2025	-2.6349962	0.008413824	0.033655294
5	2020 - 2025	-3.2656998	0.001091939	0.006551637
6	2023 - 2025	-2.7776408	0.005475511	0.027377554

Le uniche differenze significative sono quelle con i modelli aventi data di inizio 2025, che risulta avere MAPE maggiore rispetto alle altre date. Questo è dato dalla scarsità di osservazioni di questi dataset, che non permettono ai modelli di stimare dei coefficienti robusti. Tra le altre date non ci sono differenze significative, questo suggerisce che la serie di training debba avere almeno due anni di dati ($\sim$ 500 osservazioni).

3.4 Parte 1 - Stagionalità

La stessa non normalità dei dati si verifica nello studio della frequenza, che ci restituisce i seguenti residui in ANOVA:

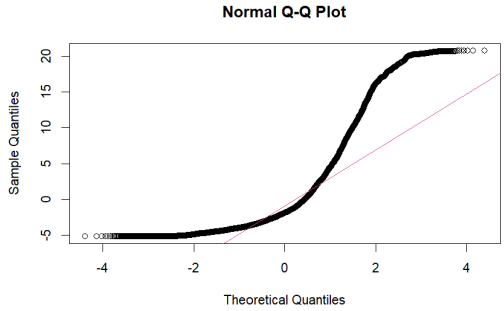

Procediamo dunque con gli stessi test. Il test Kruskal-Wallis restituisce un $p_{val} = 0.903$, che indica una non significatività delle differenze tra MAPE causate dalla stagionalità. Questo risultato è confermato dal tesi di Dunn, che restituisce p-values uguali a 1.

	Comparison	Z	P.unadj	P.adj
1	1 - 20	0.2676432	0.7889740	1
2	1 - 5	-0.1819376	0.8556317	1
3	20 - 5	-0.4493123	0.6532064	1

La stagionalità non ha dunque importanza nella stima del modello. Le serie finanziarie hanno una stagionalità debolissima, e questo si ripercuote nell'insignificatività delle differenze appena viste.

3.5 Parte 1 - Orizzonte

L'ultima sezione della prima parte dello studio è puramente esplorativa: si cerca di capire come cambiano le previsioni con l'aumentare dell'orizzonte. Per fare questo si ricorre a una regressione robusta, e si valutano i coefficienti in modo da ottenere il cambiamento medio in percentuale.

Table 1: Variazione percentuale del MAPE log incrementale per orizzonte temporale e modello

Orizzonte	ETS (%)	ARIMA (%)	Interazione (%)
30	12.70	14.23	13.71
45	51.02	38.62	38.05
60	98.41	86.73	86.57
120	222.74	204.47	204.69
Coefficiente aggiuntivo ETS: 1.05%			
*Interazioni ETS*Orizzonte: -0.33%, 9.77%, 6.35%, 5.80% rispettivamente a ARIMA*			

I risultati evidenziano un aumento del MAPE con l'allungarsi dell'orizzonte temporale per tutti i modelli. ETS mostra incrementi percentuali maggiori rispetto ad ARIMA, soprattutto per orizzonti lunghi, indicando una maggiore sensibilità agli errori di previsione a lungo termine. L'analisi con interazione conferma che l'apporto aggiuntivo di ETS rispetto ad ARIMA è modesto ma più marcato per orizzonti intermedi. In generale, le differenze tra i modelli diventano rilevanti per orizzonti più estesi, mentre per orizzonti brevi le performance risultano simili.

3.6 Parte 2 - Regressori esterni

La costruzione dei modelli con regressori esterni e la loro valutazione su dati nuovi permette di estrarre informazioni dalla loro performance basandosi sui parametri di modellazione. La metrica osservata per prima è il MAPE, che permette di stabilire come cambia la performance con l'aggiunta di regressori. Per farlo bisogna prima valutare i dati e capire il test corretto da usare

per valutare le differenze. I dati risultano non normali, procediamo dunque con test Kruskal-Wellis e Dunn.

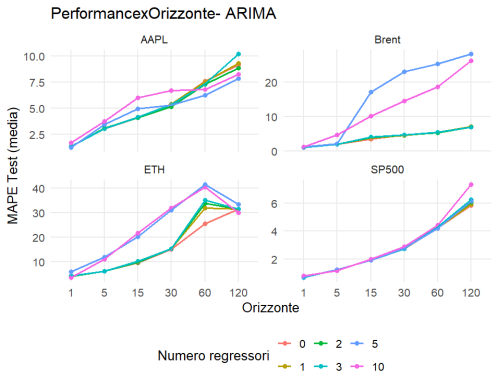

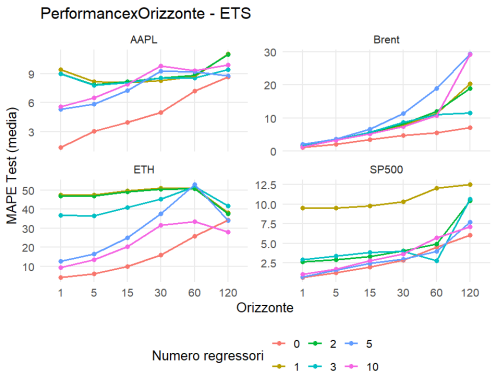

L'intuizione fornita dai grafici viene confermata dai test statistici: il numero di regressori è proporzionale all'aumento dell'errore di previsione. In particolare quando sono utilizzati 5 o 10 regressori il $MAPE$ aumenta notevolmente, e il divario con gli altri modelli aumenta con l'orizzonte.

Di fronte a questa evidenza, la problematica può avere due cause: il modello cattura tutta l'informazione senza i regressori, che una volta aggiunti aumentano solamente la complessità e la varianza della stima, senza spiegare aspetti della serie, oppure il modello non è in grado, per natura, di integrare le informazioni derivanti dai regressori. Per capire in quale casistica ricadono ARIMA ed ETS, si ricorre alla costruzione di modelli *xgboost*, che sono tra i migliori in ambito di regressione e classificazione. Seguiamo lo stesso approccio usato per i modelli ARIMA ed ETS, e confrontiamo i risultati.

Costruiti i modelli XGBoost, di seguito il comportamento relativo al numero di regressori. È evidente il peggioramento all'inserimento di 1,2 o 3 regressori, ma anche il netto miglioramento al raggiungimento di 5 o 10 regressori.

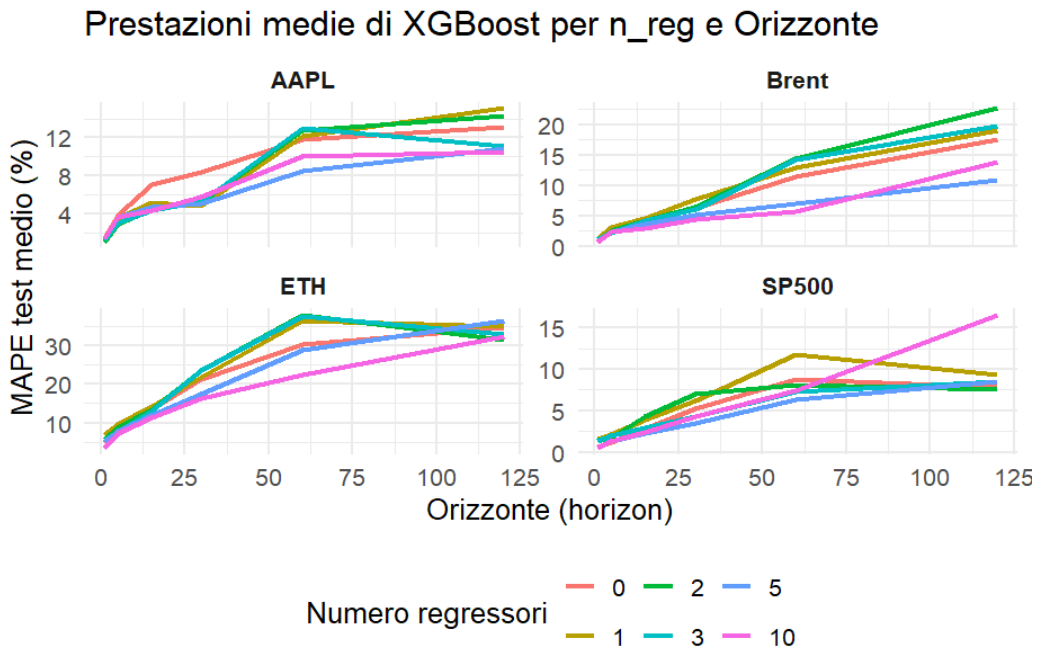

A questo punto il confronto da fare è tra i modelli migliori per ogni tipo. Si osservi il grafico seguente:

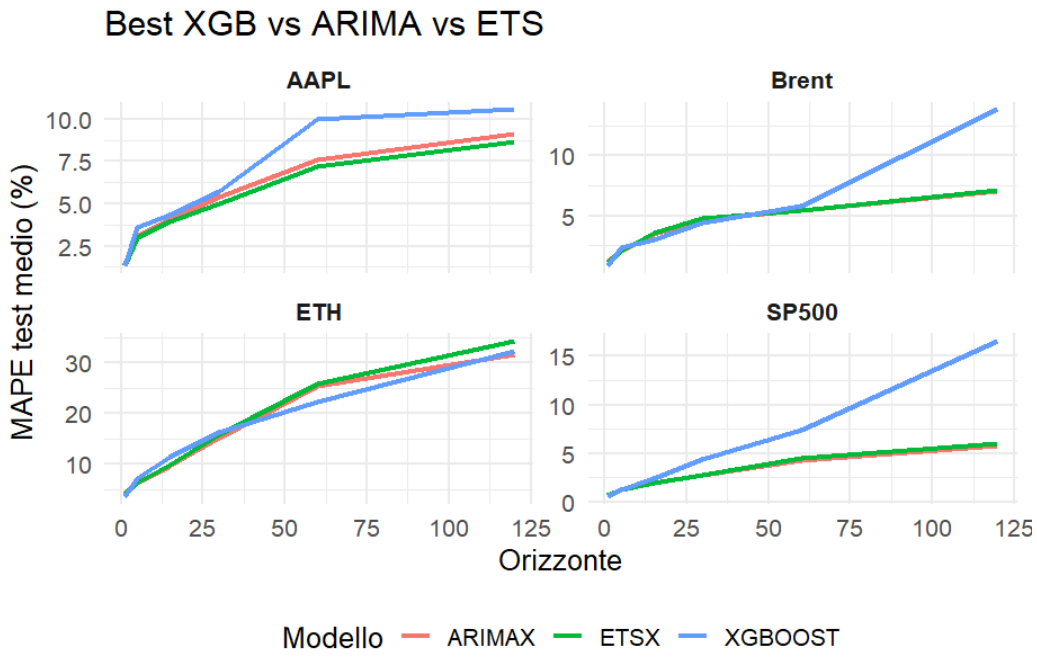

ETS ed ARIMA senza regressori sono quasi sempre migliori di XGBoost con 10 regressori. È un risultato notevole vista la potenza del modello impiegato. Il dubbio sorto dai risultati precedenti è risolto: il peggioramento delle performance di ETS e ARIMA all'integrazione di variabili esogene è dovuto alla grande capacità dei modelli di base di raccogliere le informazioni della serie.

4 Conclusioni

L'analisi condotta sui dati evidenzia come la performance dei modelli di previsione sia dipendente da molti parametri relativi al modello e ai dati, tra cui l'orizzonte temporale, le caratteristiche delle serie, le trasformazioni di pre-processing e la disponibilità di dati storici su cui allenare il modello. Per gli orizzonti brevi (15–30 giorni), ARIMA è generalmente più performante, in particolare per serie caratterizzate da alta volatilità o forte autocorrelazione, mentre ETS risulta più efficace in presenza di bassa volatilità o serie con molti outliers. Con l'aumentare dell'orizzonte (45–60 giorni), la scelta del modello diventa più sensibile alle caratteristiche strutturali delle serie: linearità, stagionalità, presenza di spikes e outliers decretano il modello preferito, e l'equilibrio tra ARIMA ed ETS si riduce. Per orizzonti lunghi (120 giorni), nessun modello domina in senso assoluto, e la performance dipende criticamente dalla combinazione di più fattori, suggerendo una scarsa abilità di entrambi i modelli di fare previsioni a lungo termine.

Il pre-processing mostra invece un quadro relativamente stabile: BoxCox è generalmente preferito in presenza di volatilità moderata e/o spikes, mentre LogRet è scelto per volatilità molto bassa o molto alta. I dati grezzi o l'eliminazione di outliers si rivelano migliori solo raramente, in condizioni estreme.

L'analisi relativa all'inizio del training evidenzia che dataset troppo brevi (meno di $\sim$ 500 osservazioni) portano a performance peggiori e maggiore variabilità nei coefficienti stimati.

La stagionalità, pur essendo spesso considerata un fattore chiave nell'analisi delle serie temporali, non ha mostrato effetti significativi sulle performance dei modelli nel contesto dei dati finanziari analizzati, a causa della stagionalità debole di questo tipo di serie.

La regressione robusta sull'orizzonte mostra come l'aumento dell'orizzonte porti a previsioni largamente errate, e come i modelli studiati possano essere considerati affidabili solamente a breve e a medio-breve termine.

La seconda parte dello studio, relativa all'implementazioone di regressori esterni, ha portato risultati interessanti. Il peggioramento delle performance

in corrispondenza dell'aggiunta di variabili esogene e il confronto vinto con i modelli XGBoost mostrano come i modelli ETS ed ARIMA siano capaci di cogliere e generalizzare le informazioni relative al livello delle serie finanziarie, e l'aggiunta di regressori esterni non porti a miglioramenti significativi della performance.

5 Appendice

Il codice utilizzato è disponibile nel repository GitHub al link in questa pagina. Le serie storiche non sono fornite direttamente in formato *.csv*, ma è presente uno script in `R` per scaricarle direttamente da Yahoo Finance: *https://github.com/marcopozzoli16/ARIMA-and-ETS-models-for-financial-series-forecasting*

6 Bibliografia

[1] Cleveland, Robert B; Cleveland, William S; Terpenning, Irma *STL: A Seasonal-Trend Decomposition Procedure Based on Loess*, Statistics Sweden, 1990

[2] John W. Tukey *Exploratory Data Analysis*, Pearson College Div, 1977 (p44)

[3] Fattore, *"Fundamentals of time series analysis, for the working data scientist*, 2024 (p67)

[4] G.E.P. Box; D.R. Cox, *"An Analysis of Transformations"*,Journal of the Royal Statistical Society. Series B (Methodological), Vol. 26, No. 2. (1964), (p211-252)

[5] R. Hyndman, *Detecting time series outliers* (https://robjhyndman.com/hyndsight/tsoutliers/)

[6] Yahoo Finance (https://finance.yahoo.com)

[7] Jeffrey A. Ryan [aut, cph], Joshua M. Ulrich [cre, aut], Ethan B. Smith [ctb], Wouter Thielen [ctb], Paul Teetor [ctb], Steve Bronder [ctb] , Quantmod package 0.4.28 (https://cran.r-project.org/package=quantmod)

[8] Kruskal, Wallis, *Use of Ranks in One-Criterion Variance Analysis*, Journal of the American Statistical Association, 1952

[9] Dunn, *Multiple comparisons using rank sums*, Journal of the American statistical association, 1964

[10] Hyndman, Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., 2022